



UNIVERSIDAD
DE GRANADA



Cátedra de Inteligencia Artificial

Universidad de Granada – Unicaja

Agente Conversacional Bancario

Integrantes

Pablo Martín Palomino `pablomarpa@correo.ugr.es`

Pablo Reyes Sousa `sousareyp@correo.ugr.es`

Natalia Yue Gallardo Pretel `nataliayue@correo.ugr.es`

Septiembre de 2026

Índice

1	Introducción y arquitectura general	3
1.1	Objetivos y enfoque de la solución	3
1.2	Arquitectura técnica	3
2	Interacción Natural y Experiencia de Usuario (UX)	4
2.1	Integración de voz y texto	4
2.2	Generación de respuestas en streaming	4
2.3	Interfaz adaptativa y accesible	5
3	Configuración, Generación y Seguridad de la Base de Datos	6
3.1	Generación de un histórico realista	6
3.2	Defensa en profundidad y aislamiento del LLM	7
4	Motor de Inteligencia Artificial	7
4.1	Gestión del historial y prevención del desbordamiento de contexto	7
4.2	System Prompt dinámico y reglas de comportamiento	8
4.3	Uso de Tool Calling	8
5	Operaciones Bancarias Seguras	9
5.1	Atajos de latencia	9
5.2	Flujo transaccional de Bizum	10
6	Consultas y Analítica Avanzada	11
6.1	Traducción del lenguaje natural a SQL para el histórico de movimientos . .	11
6.2	Enfoque híbrido: heurística y estadística	12
6.2.1	Detección de pagos recurrentes y suscripciones	12
6.2.2	Proyecciones de gasto y analítica predictiva	12
7	Motor Visual Generativo	13
7.1	Generative UI y separación de responsabilidades	13
7.2	Gráficos Vega-Lite y tablas dinámicas sin plantillas	13
8	Evaluación y resultados	14
8.1	Por qué se construyó un banco de pruebas	14
8.2	Qué se mide y por qué se separa	14
8.3	Resultados	15
8.4	Decisiones de diseño tomadas a partir de la medición	15
8.4.1	La decisión de mostrar un gráfico	16
8.4.2	El tamaño del <i>system prompt</i>	16
8.5	Validación de los componentes deterministas	17
8.5.1	Detección de pagos recurrentes	17
8.5.2	Proyección de gasto	17
8.5.3	Flujo de operaciones	18
8.6	Limitaciones conocidas	18
9	Conclusiones y Cumplimiento del Baremo	19
9.1	Conclusiones	19
9.2	Cumplimiento del baremo técnico del reto	19

10 Reparto del trabajo	20
10.1 Pablo Martín Palomino	20
10.2 Natalia Yue Gallardo Pretel	21
10.3 Pablo Reyes Sousa	21
10.4 Uso de asistentes de IA	22

1. Introducción y arquitectura general

1.1. Objetivos y enfoque de la solución

El proyecto “Habla con tu dinero” es nuestra solución al reto propuesto por la Cátedra de Inteligencia Artificial de la Universidad de Granada junto a Unicaja.

Con él, buscamos que el usuario pueda realizar consultas y operaciones financieras de manera sencilla e interactiva.

Para garantizar un funcionamiento fiable, se ha separado la interpretación de las consultas de la ejecución de las operaciones. Mientras que el modelo de lenguaje facilita la interacción con el usuario, el *backend* se encarga de obtener los datos, realizar los cálculos y ejecutar las operaciones correspondientes.

1.2. Arquitectura técnica

La aplicación se divide en tres bloques principales: la interfaz de usuario, el *backend* y la base de datos.

- **Interfaz de usuario (Frontend):** Se ha desarrollado utilizando HTML y JavaScript. La comunicación con el servidor se realiza mediante WebSockets, manteniendo una conexión abierta durante la interacción. Esto permite recibir las respuestas de forma progresiva y actualizar la interfaz dinámicamente. Además, se pueden mostrar elementos como gráficos, tablas y mensajes dentro de la propia conversación.
- **Motor principal (Backend):** Se ha desarrollado en Python utilizando FastAPI. Se encarga de recibir las peticiones del usuario, gestionar el contexto de la conversación y coordinar los diferentes componentes del sistema. También permite resolver directamente determinadas consultas sin utilizar el modelo de lenguaje. Por ejemplo, una consulta sobre el saldo de una cuenta puede resolverse directamente desde el backend, reduciendo el tiempo de respuesta.
- **Base de datos y seguridad:** La información de la aplicación se almacena en una base de datos SQLite. El acceso a los datos se gestiona desde el backend, que determina qué operaciones puede realizar cada parte del sistema. Las consultas que únicamente necesitan información utilizan acceso de lectura, mientras que las operaciones que modifican datos o implican movimientos de dinero son ejecutadas directamente por la lógica de la aplicación.

Como se muestra en la Figura 1, el *backend* se estructura de forma modular. Un controlador principal (`main.py`) gestiona las conexiones y delega el flujo en un agente (`agent.py`). Este agente utiliza un catálogo de herramientas (`tools.py`) para derivar la ejecución hacia el motor visual (`graficos.py`), la lógica analítica (`analitica.py`), las APIs bancarias (`banking_api.py`) o la base de datos (`database.py`).

Asimismo, el modelo de lenguaje (por defecto, Qwen3) se ejecuta de forma local y privada a través de Ollama, comunicándose exclusivamente con el *backend* sin acceso directo a los datos.




Figura 1: Arquitectura del sistema.

2. Interacción Natural y Experiencia de Usuario (UX)

2.1. Integración de voz y texto

El reconocimiento de voz se apoya en la API estándar del navegador (*Speech Recognition*). El micrófono se activa pulsando un botón en la interfaz o manteniendo presionada la barra espaciadora. Para dar *feedback* inmediato al usuario y evitar la sensación de latencia, se utilizan los resultados intermedios (*interim results*); de este modo, el texto va apareciendo en la pantalla a medida que se habla, enviándose al servidor justo cuando el usuario termina la locución.

Para la lectura de las respuestas se utiliza la API de síntesis de voz (*Speech Synthesis*). No se espera a que el modelo genere todo el párrafo, sino que la emisión de audio se sincroniza con el flujo de datos (*streaming*) y se va reproduciendo por frases completas, utilizando los signos de puntuación como delimitadores. Esto soluciona problemas frecuentes de lectura con cifras o decimales y evita cortes a mitad de palabra. Además, el usuario puede personalizar el tono (*pitch*), la velocidad (*rate*) y la voz del asistente desde un panel de configuración, guardándose sus preferencias localmente en el navegador (*localStorage*).

2.2. Generación de respuestas en streaming

Toda la comunicación en tiempo real entre el *cliente* y el *servidor* se realiza a través de una conexión WebSocket abierta de forma continua. Gracias a este canal, el usuario no tiene que esperar a que el servidor procese la respuesta completa para empezar a leerla,

sino que los *tokens* van apareciendo en la interfaz según los emite el modelo de lenguaje.

Además del texto de la respuesta, pueden transmitirse actualizaciones relacionadas con los datos mostrados en pantalla, como cambios en el saldo o instrucciones para representar tablas y gráficos.

Esta estrategia reduce el tiempo de espera percibido y permite que la interfaz comience a mostrar información mientras el procesamiento de la consulta continúa en segundo plano. De esta forma, la generación de la respuesta y la actualización de los distintos elementos de la interfaz pueden realizarse de forma progresiva.

La Figura 2 recoge la secuencia completa de un turno en el que el usuario hace una consulta sobre su histórico. El texto llega frase a frase y la síntesis de voz empieza con la primera; la tabla o el gráfico se generan en un tramo posterior, cuando la respuesta ya está completa.




Figura 2: Secuencia de un turno con consulta al histórico y gráfico.

2.3. Interfaz adaptativa y accesible

La interfaz no se limita a mostrar texto plano. Cuando una consulta devuelve datos comparables, el sistema lo detecta y enriquece la respuesta con gráficos o tablas interac-

tivas.

El diseño original delegaba en el modelo de lenguaje la decisión de cuándo pintar estos elementos visuales (controlado mediante la variable `VISUALES_AL_LLM`). Sin embargo, las métricas revelaron que darle esta responsabilidad al LLM bloqueaba la emisión de la voz: el modelo solía detenerse a generar la compleja estructura de datos del gráfico antes de empezar a redactar el texto en español, lo que disparaba la latencia inicial hasta unos 12,4 segundos de media.

Para resolverlo, la configuración actual oculta por defecto las herramientas visuales al modelo principal. Ahora es el *backend* quien evalúa de forma determinista el volumen y tipo de los datos obtenidos en la consulta para decidir si estos son graficables. Si lo son, lanza una llamada dedicada al LLM para construir la especificación del gráfico, pero lo hace estrictamente después de emitir el evento `fin_respuesta`. Dado que la memoria de la tarjeta gráfica empleada no permite paralelizar dos peticiones al LLM, esta segunda solicitud visual debe esperar su turno en cola obligatoriamente.

La ventaja obtenida es que el usuario escucha la respuesta hablada de inmediato (el tiempo hasta la voz se redujo a unos 6,7 segundos) y, mientras atiende a la explicación del asistente, la interfaz muestra un indicador de carga hasta que el gráfico o la tabla aparecen en pantalla.

3. Configuración, Generación y Seguridad de la Base de Datos

3.1. Generación de un histórico realista

Para evaluar el asistente en escenarios financieros verosímiles, necesitamos un conjunto de datos suficientemente rico. Para ello, el proyecto incluye un módulo de generación sintética, `seed.py`, que crea un histórico de operaciones correspondiente a un periodo de 24 meses.

El algoritmo de generación es completamente determinista, inicializado con `random.seed(42)`. Esto facilita tanto el desarrollo como la repetición de las pruebas, ya que los resultados se pueden comparar sobre un conjunto de datos conocido.

Los datos generados simulan patrones de consumo realistas que exigen distintos niveles de complejidad analítica por parte del asistente:

- **Gastos recurrentes y variables:** se combinan cargos fijos y regualres
- (como el alquiler, la luz o el agua) con transacciones con alta variabilidad (compras en supermercados, repostaje en gasolineras, restaurantes, etc.).
- **Pagos con periodicidad anual:** se incluyen operaciones separadas por periodos de tiempo más amplios, como la renovación anual del seguro del coche. Esto permite comprobar el funcionamiento de las consultas que requieren aplicar filtros sobre periodos de tiempo extensos.
- **Cambios en los gastos:** e simulan subidas de cuota a mitad del histórico, como incrementos documentados en el precio de plataformas de *streaming* para comprobar si el sistema es capaz de reconocer dicho incremento.

De esta forma, la base de datos proporciona un conjunto de pruebas más variado que permite comprobar tanto consultas sencillas como aquellas que requieren analizar información de diferentes periodos.

3.2. Defensa en profundidad y aislamiento del LLM

Una parte importante del sistema es controlar el acceso del modelo de lenguaje a la base de datos. El modelo puede generar consultas para obtener información a partir de las peticiones realizadas por el usuario, por lo que es necesario evitar que dichas consultas puedan modificar los datos almacenados.

Para ello, el acceso a la base de datos, implementado en `database.py`, incorpora varias medidas de protección independientes:

- **Acceso de solo lectura:** cuando el modelo necesita consultar información del historial, el backend utiliza una conexión SQLite en modo solo lectura mediante `mode=ro`. De esta forma, las operaciones que intenten modificar la base de datos, como `DROP` o `UPDATE`, son rechazadas por el propio motor de SQLite.
- **Validación de las consultas:** antes de ejecutar una consulta generada por el modelo, el sistema comprueba su contenido mediante una serie de expresiones regulares. Se bloquean palabras clave asociadas a operaciones de modificación de datos o de la estructura de la base de datos, como `INSERT`, `DELETE` o `ALTER`. Además, se comprueba que la consulta comience por `SELECT` o `WITH`.
- **Limitación del número de resultados:** las consultas que devuelven un número elevado de registros pueden generar una cantidad de información innecesaria para el modelo. Para evitarlo, el sistema establece un límite de 50 filas mediante la constante `MAX_FILAS = 50`. Cuando una consulta devuelve más resultados, estos se truncan antes de incorporarse al contexto de la conversación.

Estas medidas permiten separar la generación de las consultas de su ejecución. El modelo de lenguaje se encarga de construir la consulta a partir de la petición del usuario, mientras que el backend controla qué consultas pueden ejecutarse y con qué permisos se accede a la base de datos.

4. Motor de Inteligencia Artificial

4.1. Gestión del historial y prevención del desbordamiento de contexto

Los modelos de lenguaje tienen un límite en la cantidad de texto que pueden recordar a la vez (lo que se conoce como ventana de contexto, que en nuestro caso es de 8192 tokens). Como las instrucciones iniciales y la explicación de las herramientas ya ocupan bastante espacio, es necesario controlar cuánto historial de la conversación le enviamos para no saturarlo.

Para solucionar esto, la clase `Agente` (en `agent.py`) incluye una función llamada `recortar_historial` que limita la memoria a los últimos 24 mensajes. Este recorte no se hace de cualquier manera, sino que el sistema siempre conserva el primer mensaje (el

System Prompt) y busca el inicio de una intervención del usuario (`role: user`) para cortar a partir de ahí.

De esta forma, nos aseguramos de no partir por la mitad una interacción entre el modelo y una herramienta. Si cortáramos mal, el modelo podría recibir la respuesta de una herramienta sin saber por qué la había pedido, lo que provocaría un error al intentar generar el siguiente mensaje

4.2. System Prompt dinámico y reglas de comportamiento

El comportamiento del asistente y las reglas que debe seguir se definen en un *System Prompt* que construimos en el archivo `config.py`.

Este texto no es estático, sino que se genera cada vez que arranca la aplicación para poder incluir información actualizada. Por ejemplo, le pasamos la fecha de hoy usando `date.today().isoformat()` para que el modelo entienda a qué nos referimos cuando le preguntamos por los gastos de "este mes." o "la semana pasada". También le adjuntamos la estructura de la base de datos (`ESQUEMA_BD`) para que sepa qué tablas y columnas existen cuando tenga que crear consultas SQL.

Además, en este *prompt* le damos instrucciones claras sobre cómo debe expresarse. Le pedimos que trate al usuario de tú, que formatee el dinero al estilo español (por ejemplo, "1.234,56 €") y le prohibimos usar formato Markdown como negritas o cursivas. Esto último es muy importante para que el sistema que lee el texto en voz alta lo haga de forma natural, sin tropezar leyendo símbolos.

4.3. Uso de Tool Calling

Para que el modelo pueda interactuar con la aplicación, utilizamos la funcionalidad de *Tool Calling*. En el archivo `tools.py` definimos en formato JSON una lista con todo lo que el asistente puede invocar: consultar datos, preparar un envío de Bizum. . .

Para ejecutar el modelo de lenguaje en local, garantizar la privacidad de los datos y no depender de suscripciones o servicios en la nube hemos utilizado Ollama.

El problema que tenemos es que las herramientas en `tools.py` las están definidas usando la estructura de Anthropic, pero Ollama no soporta directamente este formato.

Para solucionarlo, en `agent.py` está la función `adaptar_herramientas_a_openai`, que hace de puente y traduce automáticamente nuestras herramientas al formato correcto antes de enviárselas al modelo, permitiendo que la conexión funcione sin problemas.

El proceso completo de interacción funciona como se ilustra en la [Figure 3](#): el usuario hace una pregunta, y el modelo evalúa si necesita usar alguna herramienta para responder. Si es así, interrumpe su respuesta y devuelve un mensaje especial pidiendo ejecutarla. Nuestro *backend* recibe esa petición, ejecuta el código en Python (por ejemplo, hace la consulta a la base de datos) y le devuelve el resultado al modelo añadiendo un mensaje con el rol `tool`. Finalmente, el modelo lee ese resultado y ya dispone de los datos concretos para redactar la respuesta que escuchará el usuario.




Figura 3: Flujo de interacción del Agente mediante *Tool Calling*. El Agente (`agent.py`) actúa como intermediario: controla el tamaño del historial, adapta los formatos de las herramientas y ejecuta el código en el *backend*, aislando a Ollama del acceso directo al sistema.

5. Operaciones Bancarias Seguras

5.1. Atajos de latencia

Durante las pruebas se observó que algunas consultas frecuentes no requieren utilizar el modelo de lenguaje. Un ejemplo es la consulta sobre el saldo actual, que puede resolverse directamente desde el backend. Enviar este tipo de petición al LLM añadiría aproximadamente 3 segundos al tiempo de respuesta sin aportar ninguna ventaja en este caso.

Para evitar este procesamiento innecesario, el backend, en `agent.py`, incorpora la función `es_consulta_saldo`, que permite identificar las consultas que solicitan únicamente el saldo actual. Cuando se cumple esta condición, la petición se resuelve directamente mediante la herramienta `consultar_saldo`, sin pasar por el modelo de lenguaje.

El filtro utiliza listas cerradas de palabras permitidas mediante `_RELLENO_SALDO`. Se ha optado por un criterio restrictivo para evitar que consultas que requieran información adicional sean identificadas incorrectamente como una consulta de saldo.

En este caso, los errores tienen distinto coste:

- **Falso negativo:** si una consulta sencilla no es identificada por el filtro, se envía al modelo de lenguaje. El sistema puede utilizar igualmente la herramienta `consultar_saldo`, aunque la respuesta tendrá una latencia mayor.
- **Falso positivo:** si una consulta más compleja se identifica incorrectamente como una consulta de saldo, el sistema podría devolver únicamente el saldo actual. Por ejemplo, una pregunta como “¿cuál era mi saldo el mes pasado?” requiere consultar información histórica y no debe resolverse mediante este atajo.

Por este motivo, el filtro prioriza evitar los falsos positivos, de forma que las consultas que puedan requerir un tratamiento adicional continúen su flujo normal hacia el modelo de lenguaje.

5.2. Flujo transaccional de Bizum

Las operaciones de envío de dinero se gestionan directamente desde el backend, sin delegar su ejecución en el modelo de lenguaje. El flujo se divide en varias etapas de validación y ejecución, que la Figura 4 resume con todas sus salidas:




Figura 4: Flujo de un envío de Bizum. Todas las comprobaciones se hacen en el backend y en este orden: el importe se valida antes de pedir el PIN, y el límite diario y el saldo se comprueban dentro de la misma transacción que los descuenta.

1. **Extracción y validación inicial:** la función `extraer_peticion_bizum` identifica en la petición del usuario los datos necesarios para realizar el envío, como el destinatario, el importe y el concepto. La extracción permite reconocer diferentes formas de expresar una misma operación. Antes de continuar con el proceso, el importe se comprueba para verificar que se encuentra dentro de los límites establecidos, entre 0,50€ y 1000€.
2. **Resolución del contacto:** una vez obtenido el destinatario, la función `buscar_contacto_bizum` comprueba los contactos disponibles. En caso de que el nombre proporcionado no coincida exactamente, se utilizan coincidencias parciales mediante `get_close_matches` para identificar posibles contactos. Si existe una coincidencia, esta se muestra al usuario antes de continuar con la operación.

3. **Autenticación desde el frontend:** cuando los datos de la operación son válidos, el estado de la conversación pasa a “Bizum pendiente” y el backend envía mediante WebSocket la señal `pedir_pin`. El frontend muestra entonces un teclado numérico para introducir el PIN. De esta forma, el PIN se introduce fuera del campo de texto de la conversación y no forma parte del historial que recibe el modelo de lenguaje.
4. **Validación y ejecución de la operación:** una vez validado el PIN, el backend ejecuta la función `api_enviar_bizum`. La modificación del saldo se realiza dentro de una transacción SQLite iniciada mediante `BEGIN IMMEDIATE`, utilizando `transaccion_escritura`. Esta instrucción establece el bloqueo necesario para evitar que dos operaciones de escritura se ejecuten simultáneamente sobre los mismos datos. De esta forma, la comprobación del saldo y su posterior actualización se realizan dentro de la misma transacción.

Este diseño mantiene separadas la interpretación de la petición y la ejecución de la operación bancaria. El modelo de lenguaje puede identificar la intención del usuario y proporcionar los datos necesarios, pero las validaciones y la modificación de los datos se realizan mediante la lógica del backend.

6. Consultas y Analítica Avanzada

6.1. Traducción del lenguaje natural a SQL para el histórico de movimientos

Una de las funcionalidades principales del asistente es permitir al usuario consultar su historial financiero utilizando lenguaje natural. Para ello, el sistema utiliza la técnica de *Text-to-SQL* mediante la herramienta `consultar_movimientos`. El modelo de lenguaje recibe la petición del usuario y genera una consulta en dialecto SQLite que permite obtener la información solicitada.

Para facilitar la generación de estas consultas, el *System Prompt* incluye una serie de reglas relacionadas con la estructura y el tratamiento de los datos:

- **Tratamiento de signos:** los gastos se almacenan con valores negativos y los ingresos con valores positivos. Por este motivo, cuando se necesita calcular el total de gastos, la consulta debe aplicar `SUM(-importe)` para obtener el resultado como una cantidad positiva en la respuesta.
- **Gestión temporal:** se proporcionan al modelo diferentes patrones para realizar filtros sobre fechas. Esto permite distinguir entre expresiones como “este mes” y “los últimos N meses”, utilizando las funciones de fecha disponibles en SQLite, como `strftime`.
- **Corrección de consultas:** si una consulta generada por el modelo produce un error durante su ejecución, la capa de acceso a la base de datos devuelve la información del error al agente. El modelo puede utilizar este resultado para corregir la sentencia SQL y volver a intentarlo. El número de reintentos está limitado para evitar ciclos indefinidos.

De esta forma, el modelo se utiliza para traducir la petición del usuario a una consulta sobre los datos, mientras que la ejecución de la sentencia y la gestión de los errores corresponden al backend.

6.2. Enfoque híbrido: heurística y estadística

Las consultas analíticas requieren operaciones que no resulta conveniente delegar directamente en el modelo de lenguaje. Por ejemplo, la identificación de pagos recurrentes o el cálculo de una proyección de gasto implican realizar cálculos sobre un conjunto de operaciones y detectar patrones en los datos.

Por este motivo, estas funcionalidades siguen un enfoque híbrido. El módulo `analitica.py` realiza los cálculos y obtiene los resultados a partir de los datos almacenados, mientras que el modelo de lenguaje se utiliza principalmente para interpretar la petición y redactar posteriormente la respuesta.

6.2.1. Detección de pagos recurrentes y suscripciones

La periodicidad de un pago no se almacena explícitamente en la base de datos, por lo que debe inferirse a partir del histórico de operaciones. El módulo `analitica.py` utiliza para ello la separación temporal entre los distintos cobros de un mismo concepto.

En lugar de utilizar únicamente el importe como criterio, el algoritmo analiza la regularidad de los intervalos entre pagos. Esto permite identificar pagos recurrentes aunque su importe varíe entre periodos, como puede ocurrir con recibos de suministros.

El procedimiento utiliza la mediana de los días transcurridos entre pagos y calcula su desviación típica. A partir de estos valores se obtiene un factor de irregularidad. Cuando este factor es menor o igual que 0,06 y la mediana se encuentra dentro de una cadencia conocida, como mensual, trimestral o anual, se considera que existe un patrón recurrente. Para la comparación con estas cadencias se utiliza un margen de tolerancia del 20 %.

Este procedimiento permite identificar diferentes tipos de pagos periódicos, como suscripciones o seguros anuales. Además, al disponer del histórico completo, el sistema puede detectar variaciones en el importe de un mismo pago a lo largo del tiempo.

6.2.2. Proyecciones de gasto y analítica predictiva

Para estimar el gasto total de un mes no resulta suficiente con extrapolar directamente el gasto acumulado hasta el momento. Esta aproximación puede producir resultados poco representativos al comienzo del mes, especialmente cuando existen pagos fijos que todavía no se han realizado.

El sistema divide la proyección en dos componentes:

- **Gastos fijos:** se identifican a partir de los pagos recurrentes detectados previamente. Su importe se incorpora a la proyección independientemente de que el pago se haya realizado ya durante el mes o esté pendiente.
- **Gastos variables:** se estiman a partir del ritmo de gasto del mes actual y de la media histórica de los últimos 12 meses. El peso de cada componente se modifica en función del número de días transcurridos del mes.

Durante el desarrollo se utilizó *backtesting* para comprobar el comportamiento de la proyección sobre datos históricos. Este proceso permite comparar las estimaciones que habría realizado el sistema con los gastos que realmente se produjeron y obtener una medida del error.

Los resultados del análisis se resumen antes de enviarlos al modelo de lenguaje. En lugar de proporcionarle únicamente los valores numéricos calculados, el backend puede generar conclusiones como “fiabilidad alta” o “tendencia por encima de la media”. De

esta forma, el modelo recibe información ya procesada y se encarga principalmente de presentarla al usuario.

7. Motor Visual Generativo

7.1. Generative UI y separación de responsabilidades

El asistente puede complementar las respuestas de texto con componentes visuales generados a partir de los datos obtenidos en las consultas. Para ello, se utiliza un enfoque de *Generative UI*, en el que la estructura del componente visual se determina en función de la información disponible.

La generación de una visualización completa por parte del modelo de lenguaje, incluyendo tanto su estructura como los datos, presenta algunos inconvenientes. Por un lado, aumenta la cantidad de información que debe procesar el modelo y, por tanto, el tiempo necesario para generar la respuesta. Por otro, permitir que el modelo reproduzca directamente los valores obtenidos de la base de datos puede introducir errores en los datos mostrados.

Para evitar estos problemas, el motor visual, implementado en `graficos.py`, separa la definición de la visualización de los datos que se muestran:

- **Decisión de viabilidad:** después de ejecutar una consulta SQL, el backend analiza el resultado para determinar si puede representarse mediante un componente visual. Por ejemplo, se puede considerar representable un resultado con varias filas y columnas numéricas, o una fila que contenga varias métricas que puedan compararse.
- **Diseño de la visualización:** cuando el resultado es apto para su representación, se realiza una llamada independiente al modelo de lenguaje. En esta llamada se proporcionan los nombres de las columnas y una muestra reducida de los datos. El modelo utiliza esta información junto con el contexto de la consulta para determinar si resulta más apropiado utilizar una tabla o un gráfico y generar la estructura correspondiente. La respuesta incluye también el campo `razonamiento`, que indica el motivo de la elección.
- **Inyección de los datos:** el modelo no genera los valores que se muestran finalmente al usuario. Devuelve únicamente la estructura del componente visual. El backend incorpora posteriormente los datos reales obtenidos de la base de datos antes de enviar el componente al frontend mediante WebSocket.

Esta separación permite que el modelo se encargue de determinar cómo representar la información, mientras que los datos mostrados proceden directamente de la consulta realizada por el backend.

7.2. Gráficos Vega-Lite y tablas dinámicas sin plantillas

El sistema no utiliza una colección fija de plantillas para representar los resultados. En su lugar, el modelo de lenguaje genera la estructura del componente a partir del tipo de información obtenida y de la consulta realizada.

- **Gráficos con Vega-Lite v5:** cuando los datos se pueden representar de forma más adecuada mediante una visualización, el modelo genera una especificación JSON compatible con Vega-Lite. En ella determina el tipo de marca utilizado mediante **mark**, como líneas, barras o áreas, y establece la correspondencia entre las columnas y los diferentes elementos del gráfico mediante **encoding**. También puede definir los títulos y etiquetas que se muestran en la interfaz.
- **Tablas dinámicas:** cuando resulta más importante consultar valores concretos o cuando los resultados contienen varios atributos, el modelo puede seleccionar una representación mediante tabla. En este caso, determina qué columnas deben mostrarse y en qué orden, además de asignar reglas de formato mediante etiquetas como “euros”, “fecha” o “texto”. El frontend utiliza esta información para representar cada columna con el formato correspondiente.

De esta forma, la representación visual se genera a partir de los resultados concretos de cada consulta, sin necesidad de definir previamente una plantilla específica para cada tipo de pregunta.

8. Evaluación y resultados

8.1. Por qué se construyó un banco de pruebas

Un asistente conversacional puede dar una respuesta equivocada con total naturalidad. A diferencia de un error de programación, que se manifiesta con una excepción, una cifra incorrecta expresada en una frase bien construida resulta indistinguible de una correcta para quien la escucha.

Durante el desarrollo se detectó un caso que ilustra el problema. Ante la pregunta “¿he gastado más este año que el año pasado?”, el modelo generaba una consulta con `strftime('%Y-%m')` en lugar de `strftime('%Y')`. La consulta comparaba el mes actual contra el mes anterior, pero la respuesta los presentaba como años. El asistente respondía que se había gastado más este año cuando la realidad era 17.870 € frente a 26.643 €: la conclusión estaba invertida y se expresaba con seguridad. Revisando la interfaz, la respuesta resultaba convincente.

Por este motivo se desarrolló `tests/evaluar.py`, un banco de preguntas que se ejecuta contra el agente real y mide su comportamiento de forma sistemática.

8.2. Qué se mide y por qué se separa

El banco contiene 44 preguntas etiquetadas, distribuidas entre los tipos de consulta que menciona el enunciado (gastos, comparativas y suscripciones) y otros añadidos durante el desarrollo: seguimiento multiturno, operaciones de Bizum, saldo, ingresos, preguntas ambiguas, límites del asistente y previsión.

Se puntúan cuatro indicadores por separado, porque responden a fallos de naturaleza distinta:

- **Elección de herramienta.** Preguntar por las suscripciones y que el modelo escriba una consulta SQL es un fallo aunque la cifra final sea correcta. Se registra mediante un espía sobre `ejecutar_tool`, de forma que también se observan las resoluciones directas del backend, que no aparecen en el historial del modelo.

- **Respuesta final.** Que la consulta sea correcta no garantiza que el modelo traslade bien la cifra al texto. Es lo único que oye el usuario, y se comprueba que los valores esperados aparezcan con formato español.
- **Refuerzo visual.** Se puntúa en los dos sentidos: no mostrar nada cuando hay varios valores comparables es un fallo, y mostrar algo cuando la respuesta es un único dato también. Una tabla cuenta igual que un gráfico, porque la elección entre ambos corresponde al modelo y las dos son respuestas válidas.
- **Validez de la especificación.** Que llegue un gráfico no significa que se vea. Una especificación sin el campo `mark` supera la validación del backend y falla después en el renderizado, sin dejar rastro. Se puntúa por separado del indicador anterior porque son fallos de cosas distintas: uno mide al modelo decidiendo y el otro al modelo redactando.

Se mide además un quinto indicador sin puntuación, como diagnóstico: se ejecutan la consulta generada por el agente y una de referencia escrita a mano, y se comparan los valores obtenidos. No cuenta para el resultado porque el modelo puede elegir una interpretación distinta y defendible —otro periodo, otra forma de calcular una media— y divergir de la referencia sin estar equivocado. Nunca se compara el texto de la consulta: existen muchas consultas correctas distintas para la misma pregunta.

La latencia se mide en dos tramos. El relevante es el tiempo hasta el evento `fin_respuesta`, en el que el texto de la respuesta ya está completo. Es una cota superior de la espera que percibe el usuario, porque la síntesis de voz empieza antes, con la primera frase recibida. El motor visual se ejecuta después de ese evento de forma deliberada, así que contabilizar únicamente el tiempo total penalizaría un trabajo que ya no bloquea la respuesta.

8.3. Resultados

Las mediciones se realizan con tres repeticiones de las 44 preguntas, sobre `qwen3:8b` y con la base de datos regenerada previamente.

Indicador	Resultado
Elección de herramienta	97,6 %
Respuesta final correcta	88,9 %
Refuerzo visual cuando corresponde	100 %
Especificaciones válidas	100 %
Latencia mediana hasta la voz	3,3 s

Cuadro 1: Resultados sobre 44 preguntas y 3 repeticiones.

La variabilidad entre ejecuciones del mismo sistema es de uno o dos casos sobre 126, por lo que las comparaciones entre configuraciones se realizan siempre con repeticiones. Una diferencia de dos casos en una única ejecución no constituye una señal.

8.4. Decisiones de diseño tomadas a partir de la medición

El banco de pruebas no se utilizó únicamente para verificar el resultado final. En varios casos, la medición contradijo una decisión previa y motivó un cambio de arquitectura.

8.4.1. La decisión de mostrar un gráfico

Inicialmente, la decisión de acompañar una respuesta con un gráfico se dejaba al modelo mediante instrucciones en el *system prompt*. La medición mostró que esa decisión no era estable: variaba ante cualquier modificación del *prompt*, incluso ante cambios que no trataban sobre gráficos.

Pregunta	v1	v2	v3	v4
Ranking de comercios	0/3	2/3	0/3	0/3
Comparación mensual	0/3	0/3	0/3	0/3
Comparación por categorías	0/3	2/3	2/3	0/3
Serie de seis meses	0/3	3/3	3/3	0/3
Comparación interanual	0/3	0/3	0/3	0/3
Evolución mensual	3/3	3/3	3/3	3/3

Cuadro 2: Veces que cada pregunta produce un gráfico, sobre cuatro versiones del *system prompt*. Entre la tercera y la cuarta solo cambiaron dos líneas relativas al tratamiento de fechas.

Dentro de cada versión el comportamiento es prácticamente determinista, pero entre versiones cambia sin relación con el contenido modificado. Cinco de las seis preguntas no producían gráfico en la versión final; la única que funciona de forma consistente es la que contiene una petición visual explícita (“muéstrame la evolución”).

A partir de este resultado se reorganizó la responsabilidad. La decisión de *si* existe algo que representar pasó al backend, mediante una regla determinista sobre la forma del resultado: varias filas con alguna columna numérica, o una sola fila con dos o más cifras comparables. La decisión de *qué* representación utilizar —tabla o gráfico—, con qué marca, qué ejes y con qué justificación, permanece en el modelo, en una llamada dedicada de tarea única.

El indicador pasó del 16,7 % al 100 %, sin variación en la precisión de las respuestas ni en la latencia percibida. Conviene subrayar que la decisión que se trasladó al código no es una decisión de diseño visual, sino una comprobación mecánica sobre la estructura de los datos.

8.4.2. El tamaño del *system prompt*

Durante el desarrollo, el *system prompt* fue creciendo al incorporar nuevas reglas. La medición mostró que ese crecimiento degradaba reglas anteriores: una pregunta de comparación entre categorías pasó de 3/3 a 0/3 a lo largo de varias sesiones, con el ejemplo que la resolvía intacto en el *prompt*.

La causa era la duplicación: las mismas seis herramientas se describían tanto en el *prompt* como en sus esquemas JSON, y ambos textos se envían en cada petición. Se eliminó la parte duplicada —la que indica cuándo llamar a cada herramienta, que el esquema ya expresa y en mejor posición, junto a la definición de la función— y se conservó la que el esquema no puede expresar: cómo interpretar el resultado devuelto.

Se verificó una por una que ninguna de las diecisiete reglas obtenidas mediante medición se hubiera perdido en el proceso. Se recuperaron dos preguntas, una de ellas registrada desde el inicio como limitación asumida del modelo: no lo era.

	Antes	Después
Contexto fijo por petición	3.822 tokens	3.208 tokens
Porcentaje de la ventana	47 %	39 %
Elección de herramienta	97,6 %	97,6 %
Respuesta final correcta	85,7 %	90,5 %

Cuadro 3: Efecto de eliminar las instrucciones duplicadas.

8.5. Validación de los componentes deterministas

Los componentes que no dependen del modelo se validan por separado, con pruebas que no requieren el LLM y que por tanto son deterministas y rápidas.

8.5.1. Detección de pagos recurrentes

Los umbrales del detector se ajustaron observando una única base de datos, lo cual no demuestra que generalicen. Para comprobarlo se regenera el histórico con 500 semillas distintas y se contrasta el resultado con la verdad conocida por construcción: 0 falsos negativos, 1 falso positivo (0,2 % de los históricos generados), ninguna cadencia mal clasificada y el seguro anual detectado en las 500 semillas.

Dos decisiones de diseño provienen de esa medición. La primera, reducir el umbral de irregularidad de 0,10 a 0,06. La segunda, ampliar el histórico generado de 15 a 24 meses, que por sí sola redujo los falsos positivos de 23 a 0: con más histórico, los comercios no recurrentes acumulan cargos suficientes para que su irregularidad resulte evidente.

Conviene señalar el límite de esta validación. El generador asigna a los pagos recurrentes un día fijo de cada mes, mientras que los gastos no recurrentes caen en un día aleatorio. La prueba demuestra por tanto que el detector distingue un cargo de día fijo de uno de día aleatorio, y que no clasifica como recurrente un gasto habitual: una compra semanal, incluso perfectamente regular, no se detecta como suscripción, porque el clasificador solo admite cadencias reconocidas. No cubre, en cambio, el desplazamiento del día de cobro habitual en las domiciliaciones reales, que se cargan el siguiente día hábil. Medido posteriormente, el detector reconoce la cadencia con desplazamientos de hasta dos días, y deja de reconocerla a partir de tres.

8.5.2. Proyección de gasto

El estimador de la proyección a fin de mes se seleccionó comparando tres alternativas sobre los 23 meses completos del histórico, midiendo el error de cada una según el día del mes en que se realiza la estimación.

Método	Día 5	Día 10	Día 15	Día 20
Proporción directa	174,5 %	73,3 %	46,1 %	25,9 %
Pagos fijos por separado	31,7 %	18,4 %	13,6 %	10,6 %
Combinado con media histórica	8,7 %	7,6 %	8,4 %	7,7 %

Cuadro 4: Error medio de cada estimador según el día del mes.

La proporción directa resulta inservible porque el alquiler y los recibos domiciliados se cargan a principios de mes: el día 3, con 890,34 € gastados de los cuales 844,80 € corresponden a pagos fijos, una regla de tres proyectaría 8.903 € para el mes completo.

El estimador adoptado no extrapola los pagos fijos, cuyo coste mensual ya conoce el detector de recurrencia, y combina el ritmo de gasto variable observado con la media histórica, ponderando según lo avanzado que esté el mes. El error se mantiene estable en torno al 8 % durante todo el mes, lo que permite ofrecer una previsión útil desde los primeros días.

Cada proyección se acompaña de su margen de error, calculado aplicando el mismo estimador a cada mes pasado y midiendo la desviación. El margen varía considerablemente según la categoría: 0 % en alquiler o gimnasio, que son pagos fijos conocidos; en torno al 20 % en supermercado o gasolina; y superior al 100 % en los Bizums enviados, que son impredecibles por naturaleza. Ofrecer una cifra única para todas las categorías habría resultado igual de creíble y sustancialmente menos honesto.

8.5.3. Flujo de operaciones

El envío de Bizums se valida mediante 35 comprobaciones que recorren el flujo completo sin intervención del modelo: reconocimiento de la petición, validación del importe, resolución del contacto, gestión del PIN y atomicidad de la escritura.

Esta prueba se escribió antes de refactorizar el flujo, precisamente porque el banco de preguntas no cubre ese camino: sus preguntas sobre Bizums son consultas sobre envíos pasados, que se resuelven mediante SQL. Era posible alterar el comportamiento del envío sin que ninguna métrica lo reflejara.

Una de las comprobaciones verifica que el bloqueo de escritura se adquiere antes de la primera lectura. Sin esa garantía, dos envíos simultáneos leen el mismo saldo, ambos superan la comprobación y una actualización sobrescribe a la otra: en la reproducción del caso, dos envíos de 600 € sobre un saldo de 1.000 € resultaban ambos aprobados. La comprobación se formula sobre la propiedad que lo impide y no sobre el síntoma, ya que una condición de carrera solo se manifiesta cuando dos hilos coinciden en una ventana de milisegundos y una prueba que dependiera de ello resultaría inestable.

8.6. Limitaciones conocidas

La evaluación permite delimitar con precisión lo que el sistema no resuelve:

- **Resolución de referencias entre turnos.** Ante la secuencia “¿cuánto he gastado en supermercado este año?”, “¿y en restaurantes?”, “¿y el año pasado?”, el modelo resuelve la tercera pregunta contra la primera y responde sobre supermercado. Es un comportamiento sistemático, no ocasional.
- **Previsión de meses futuros.** La herramienta proyecta únicamente el mes en curso. Ante una pregunta sobre el mes siguiente, el modelo responde con la cifra del mes actual sin advertir la diferencia. Se probaron dos correcciones —una regla en el *prompt* y un campo explícito en la respuesta de la herramienta— y ninguna resultó efectiva.
- **Preguntas sin periodo explícito y consultas sobre terceros.** Se documentan como limitaciones asumidas, con la salvedad de que una de las inicialmente clasificadas como tales resultó no serlo: desapareció al reducir el tamaño del *system prompt*.

Delimitar estas limitaciones con precisión resulta más útil que un resultado global elevado, ya que indica en qué condiciones conviene confiar en el sistema y en cuáles no.

9. Conclusiones y Cumplimiento del Baremo

9.1. Conclusiones

El desarrollo de “Habla con tu dinero” ha permitido implementar un asistente conversacional capaz de consultar información financiera, realizar determinadas operaciones y generar representaciones visuales a partir de las peticiones del usuario.

Uno de los principales aspectos de la arquitectura es la separación de responsabilidades entre el modelo de lenguaje y el código de la aplicación. El LLM se utiliza principalmente para interpretar las peticiones, generar consultas SQL, seleccionar herramientas y definir la estructura de las visualizaciones. Por otro lado, el backend se encarga de realizar los cálculos, consultar los datos y ejecutar las operaciones que modifican el estado de la aplicación.

Esta separación también se aplica a las operaciones que requieren un mayor control, como el envío de Bizums. La validación de los datos, la autenticación mediante PIN y la actualización del saldo se realizan fuera del modelo de lenguaje y mediante la lógica del backend y las transacciones de la base de datos.

Durante el desarrollo también se han realizado diferentes ajustes para reducir el tiempo de respuesta. Un ejemplo es la resolución directa de determinadas consultas, como la del saldo, que se resuelven sin recurrir al modelo.

Otro es la posición del motor visual dentro del turno. La generación de la tabla o el gráfico no se ejecuta en paralelo con la respuesta —la memoria disponible en la tarjeta gráfica no permite atender dos peticiones simultáneas al modelo—, sino después del evento `fin_respuesta`, cuando el texto ya se ha emitido y la síntesis de voz, que arranca con la primera frase, está en marcha. De este modo la generación queda fuera del camino crítico: el usuario escucha la respuesta de inmediato y el elemento visual aparece mientras la está oyendo, acompañado de un indicador de que se está preparando. En las pruebas realizadas, este cambio redujo el tiempo hasta la respuesta hablada de 12,4 a 6,7 segundos en las preguntas que generan un elemento visual.

En conjunto, el proyecto muestra que es posible utilizar un modelo de lenguaje como parte de una aplicación de gestión financiera manteniendo fuera del modelo las operaciones que requieren cálculos, validaciones y modificaciones de los datos. Esta organización permite aprovechar el procesamiento de lenguaje natural sin depender del modelo para las partes críticas de la aplicación.

9.2. Cumplimiento del baremo técnico del reto

El desarrollo se ha realizado tomando como referencia los criterios de evaluación establecidos para el reto. Las principales funcionalidades implementadas son las siguientes:

- **Text-to-SQL (30 puntos):** se ha implementado la traducción de consultas en lenguaje natural a sentencias SQL mediante la herramienta `consultar_movimientos`. El esquema de la base de datos se incorpora al *System Prompt* y el sistema permite corregir determinadas consultas cuando se produce un error durante su ejecución. Las consultas sobre el histórico se realizan mediante una conexión SQLite de solo lectura (`mode=ro`) y se aplican validaciones adicionales antes de ejecutarlas.
- **Operaciones Bancarias (10 puntos):** el asistente permite realizar operaciones como la consulta del saldo y el envío de dinero mediante Bizum. El flujo de Bizum

incluye la extracción y validación del importe, la resolución del destinatario, la introducción del PIN desde el frontend y la ejecución de la operación mediante una transacción SQLite iniciada con `BEGIN IMMEDIATE`.

- **Gráficos sin plantillas (10 puntos):** las visualizaciones se generan a partir de los resultados concretos de cada consulta, sin utilizar una plantilla fija para cada caso. El modelo genera especificaciones compatibles con Vega-Lite v5 y determina elementos como el tipo de gráfico, los ejes y los títulos.
- **Lógica visual (10 puntos):** el backend analiza inicialmente si los resultados obtenidos son adecuados para una representación visual. Cuando lo son, el modelo determina si la información debe mostrarse como tabla o como gráfico y genera la estructura correspondiente. La decisión incluye el campo `razonamiento`, utilizado para indicar el motivo de la elección.
- **Analítica avanzada (extra):** se han implementado funcionalidades adicionales para analizar los movimientos del usuario, como la detección de pagos recurrentes y la proyección del gasto mensual. Estos cálculos se realizan en Python mediante reglas y métodos estadísticos, mientras que el modelo de lenguaje se utiliza para interpretar la consulta y presentar los resultados.

10. Reparto del trabajo

El desarrollo se ha organizado de forma que cada integrante asumiera la responsabilidad principal de un conjunto de áreas del proyecto. La Tabla 5 lo resume y los apartados siguientes lo detallan.

Integrante	Áreas principales
Pablo Martín Palomino	Base del agente y modelo local, motor visual, analítica avanzada, evaluación y robustez del flujo de Bizum
Natalia Yue Gallardo Pretel	Flujo conversacional de Bizum, seguridad y experiencia en la interfaz, y redacción de la memoria
Pablo Reyes Sousa	Interacción por voz y personalización de la voz del asistente

Cuadro 5: Resumen del reparto del trabajo.

10.1. Pablo Martín Palomino

- Base inicial del proyecto: servidor FastAPI con WebSocket, ejecución de consultas SQL en modo solo lectura, primeros gráficos con Vega-Lite y voz en el navegador.
- Planificación del trabajo y migración a un modelo local (`qwen3:8b` sobre Ollama), incluido el script de arranque que amplía el contexto a 8192 tokens.

- Detección de pagos recurrentes y control del tamaño del contexto del modelo.
- Proyección del gasto a fin de mes, con el margen de error de cada categoría medido sobre el histórico.
- Motor visual: llamada dedicada para generar la especificación, decisión determinista en el backend sobre cuándo mostrar un elemento visual y tablas como segunda representación.
- Banco de evaluación de 44 preguntas y pruebas automáticas del flujo de Bizum y del detector de recurrencia.
- Robustez del flujo de Bizum: validación del importe antes de pedir el PIN, unificación de las dos vías de entrada, transacción `BEGIN IMMEDIATE` y acceso a la base de datos fuera del bucle de eventos.
- Reducción de la latencia: *streaming* por frases, recorte del *system prompt* y generación visual posterior a la respuesta hablada.
- Documentación del repositorio en español e inglés.

10.2. Natalia Yue Gallardo Pretel

- Atajo para consultar el saldo sin llamar al modelo y reducción del número de tokens y llamadas por respuesta.
- Flujo conversacional de Bizum: validación del contacto, herramienta de contactos, importe opcional y normalización de las respuestas afirmativas y negativas en la confirmación.
- Primera versión del historial de conversación y corrección de las consultas de gasto, incluida la eliminación del formato Markdown en las respuestas.
- Capa de seguridad en la interfaz: pantalla de acceso, teclado numérico para el PIN y aviso de los intentos restantes.
- Experiencia de usuario: justificante de Bizum con concepto, personalización del perfil, del color y del tamaño de letra, y logotipos de los comercios en las tablas.
- Extracción de información financiera mediante imágenes aportadas por el usuario.
- Estructura de la memoria en $\text{\LaTeX}$, portada y redacción de los capítulos.

10.3. Pablo Reyes Sousa

- Mejora de la interacción por voz: activación del micrófono con la barra espaciadora e indicador visual de que la lectura en voz alta está activada.
- Panel de personalización de la voz del asistente: elección entre las voces disponibles en español, ajuste del tono y de la velocidad, y prueba de la configuración antes de guardarla.

10.4. Uso de asistentes de IA

Durante el desarrollo se han utilizado asistentes de programación basados en inteligencia artificial como apoyo en la escritura y revisión de código, la depuración de errores, la redacción de documentación y la generación del catálogo de comercios de los datos ficticios. Su uso ha estado siempre sujeto a la revisión del equipo.